

Comparação de modelos para a estimativa de volume de passageiros com base na matriz origem-destino da telefonia móvel

Fernando Antônio Pavão
Instituto Tecnológico de Aeronáutica
and
Lucas Coelho e Silva
Instituto Tecnológico de Aeronáutica

5 de outubro de 2020

Resumo

The text of your abstract. 200 or fewer words.

Keywords: Modelo gravitacional, Machine Learning, Rede neural, Regressão linear múltipla

1 Introdução

A previsão de demanda de passageiros é um objeto de pesquisa multidisciplinar cujos resultados podem auxiliar vários participantes do mercado de transporte aéreo.

Do ponto de vista das linhas aéreas, a previsão de demanda de passageiros pode ser utilizada para auxiliar na definição de novas rotas. Para administradores de aeroportos, os resultados têm aplicabilidade quanto à estimativa dos requisitos de infraestrutura, por exemplo.

Existem diversas metodologias para a estimativa do volume de passageiros em dado período de tempo. Na prática, é comum que a parte interessada compare a previsão feita por mais de um modelo ao traduzir as estimativas para uma decisão de negócio (Grosche et al. 2007).

Dessa forma, justifica-se um estudo que compare diferentes modelos para a previsão de demanda. Neste estudo, dois modelos foram construídos e avaliados: o modelo gravitacional, pioneiro e amplamente utilizado, e modelos de aprendizagem de máquina, com a utilização de redes neurais e regressão linear múltipla.

Os modelos foram construídos tendo como variáveis independentes dados geoeconômicos, disponibilizados pelo IPEA (2020). O volume real de passageiros utilizado é o disponível na matriz origem-destino construída a partir dos dados de telefonia móvel, disponibilizados na base de dados Hórus.

2 Modelos de previsão de demanda

2.1 Modelo gravitacional

Os modelos gravitacionais foram os modelos causais pioneiros para a previsão do volume de passageiros (Grosche et al. 2007). Sua utilizados para explicar como o tráfego se distribui nos pares-cidade, indicando o comportamento dos viajantes.

De acordo com Grosche et al. (2007), a hipótese fundamental dos modelos gravitacionais é a de que ele pode ser construído a partir de variáveis econômicas ou sociais. Não obstante, essas variáveis podem ser de natureza geoeconômica, como população e dis-

tribuição de renda, ou relacionadas ao serviço de transporte aéreo em si, como preço de passagens, ou conveniências disponíveis no aeroporto.

A equação clássica do modelo gravitacional é dada, para um par-cidade, por:

$$T_{ij} = kV_i^\mu W_j^\alpha d_{ij}^{-\beta}$$

onde:

- T_{ij} é o fluxo entre a origem e o destino;
- V_i é a “emissibilidade” da origem;
- W_j é a “atratividade” do destino;
- d_{ij} é a resistência ao fluxo - como a distância;
- k é a constante de proporcionalidade;
- μ , α e β são os parâmetros do modelo.

A utilização do modelo gravitacional para a modelagem do volume de passageiros no transporte aéreo é vasta na literatura. Nõmmik & Kukemelk (2016) desenvolveram um modelo gravitacional para a modelagem do volume de passageiros em rotas regionais, aplicado ao Aeroporto de Tallinn (EETN). Nõmmik & Kukemelk (2016) utilizaram variáveis relacionadas ao serviço na construção do modelo, e demonstraram que o modelo gravitacional pode ser uma ferramenta simples e efetiva para uma análise primária conduzida por planejadores de rota na linha aérea. Grosche et al. (2007) propuseram modelos gravitacionais utilizando variáveis geoeconômicas, visando a aplicabilidade do modelo em pares-cidade que atualmente não possuam rotas estabelecidas. Os dois modelos propostos apresentaram erro baixo e foram validados estatisticamente.

2.2 Modelos de *machine learning*

Ainda que menos utilizado que o modelo gravitacional para a modelagem de volume de passageiros, encontram-se na literatura aplicações de modelos de *machine learning* nesse contexto.

Pourebrahim et al. (2018) estudaram um modelo gravitacional e outro de rede neural para a predição de fluxo de passageiros. Ainda que o foco do estudo tenha sido a melhora

das predições com a utilização de dados de redes sociais, a comparação entre os modelos foi apresentada. De acordo com os autores, em termos da Raiz do Erro Quadrático Médio (RMSE, do inglês *Root Mean Squared Error*), o modelo gravitacional apresentou resultados melhores, enquanto o modelo de rede neural apresentou um coeficiente de determinação (R^2) mais elevado.

Erjongmanee & Kongsamutr (2018) comparam modelos de regressão linear múltipla e rede neural com o gravitacional para o volume de passageiros doméstico na Tailândia. Tanto os modelos de regressão linear múltipla como os de rede neural apresentaram erros baixos.

3 Desenvolvimento dos modelos

3.1 Consolidação dos dados

Talvez seja benéfico tratar da parte comum e de decisões que afetem os dois modelos em uma seção unificada. Exemplo: variáveis geoeconômicas utilizadas.

3.2 Modelo gravitacional

Explicar as análises feitas para o desenvolvimento do modelo gravitacional. Aqui, tratar da construção do modelo em si, calibragem dos parâmetros, quantificação dos erros e validação da hipótese nula.

3.3 Modelos de *machine learning*

Explicar as análises feitas para o desenvolvimento dos modelos de machine learning.

3.3.1 Regressão linear

Inserir desenvolvimentos.

3.3.2 Rede neural

Inserir desenvolvimentos.



Figura 1: Figura de amostra

4 Conclusões

Conclusão dos resultados obtidos.

Referências

Erjongmanee, S. & Kongsamutr, N. (2018), Air Passenger Estimation Using Gravity Model and Learning Approaches: Case Study of Thailand, *in* ‘2018 5th International Conference on Advanced Informatics: Concept Theory and Applications (ICAICTA)’, IEEE, Krabi, pp. 36–41.

URL: <https://ieeexplore.ieee.org/document/8541335/>

Grosche, T., Rothlauf, F. & Heinzl, A. (2007), ‘Gravity models for airline passenger volume estimation’, *Journal of Air Transport Management* **13**(4), 175–183.

URL: <https://linkinghub.elsevier.com/retrieve/pii/S0969699707000178>

IPEA (2020), ‘Atlas do desenvolvimento humano’. <http://www.atlasbrasil.org.br/acervo/biblioteca>.

Nõmmik, A. & Kukemelk, S. (2016), ‘DEVELOPING GRAVITY MODEL FOR AIRLINE REGIONAL ROUTE MODELLING’, *Aviation* **20**(1), 32–37.

URL: <http://journals.vgtu.lt/index.php/Aviation/article/view/697>

Pourebrahim, N., Thill, J.-C., Sultana, S. & Mohanty, S. (2018), ‘Enhancing Trip Distribution Prediction with Twitter Data: Comparison of Neural Network and Gravity Models’, p. 4.